

---

# ***Classification of Freshness Quality of Broiler Chicken Breast with Transfer Learning Using ResNet, Inception, and Xception Architectures***

Klasifikasi Kualitas Kesegaran Daging Dada Ayam Broiler dengan Transfer Learning Menggunakan Arsitektur ResNet, Inception, dan Xception

**Linggar Maretva Cendani<sup>1</sup>, Michael Axel Pangestu<sup>2</sup>, Fatah Muria<sup>3</sup>**

<sup>1,2,3</sup> Informatika, Universitas Diponegoro, Indonesia

<sup>1</sup>linggarmc@students.undip.ac.id, <sup>2</sup>axelp2279@students.undip.ac.id,

<sup>3</sup>fatahmuria@students.undip.ac.id

## ***Informasi Artikel***

*Received: 18 June 2020*

## ***Abstract***

***Purpose:*** Compare the performance of ResNet, InceptionV3, and Xception for chicken breast meat quality classification.

***Design/methodology/approach:*** The three algorithms compared in this study are transfer learning with ResNet, InceptionV3, and Xception architectures. The data used in this study consisted of 1300 images of chicken breast meat, 650 from the fresh class, and 650 from the rotten class. Preprocessing is done by resizing and normalizing the pixel values in the image, including the division into 80% training data and 20% test data. The training data was trained using the ResNet, InceptionV3, and Xception models that had been previously trained on ImageNet. Parameters that are changed during training are epoch, momentum, and learning rate. The resulting model is then used for testing. Accuracy, precision, and recall were monitored to determine the best model for classifying chicken breast meat.

***Findings/result:*** The highest accuracy obtained in this study was 95.67%. This accuracy is obtained by ResNet and Inceptionv3 methods. The best results of ResNet were obtained with a learning rate of 0.0007, without momentum, and epochs of 200. The best results of Inceptionv3 were obtained with a learning rate of 0.0003, momentum of 0.9, and epochs of 200.

***Originality/value/state of the art:*** Comparison of transfer learning on ResNet, Inceptionv3, and Xception models for

---

*quality classification of chicken breasts has never been done before.*

*Keywords: chicken breast; transfer learning; deep learning; ResNet; Inceptionv3; Xception*  
*Kata kunci: dada ayam; transfer learning; deep learning; ResNet; Inceptionv3; Xception*

---

## **Abstrak**

**Tujuan:** Membandingkan performa ResNet, InceptionV3, dan Xception pada klasifikasi kualitas daging dada ayam.

**Perancangan/metode/pendekatan:** Tiga Algoritma yang dibandingkan dalam penelitian ini adalah transfer learning dengan arsitektur ResNet, InceptionV3, dan Xception. Data yang digunakan dalam penelitian ini terdiri dari 1300 citra daging dada ayam, 650 dari kelas segar, dan 650 dari kelas busuk. Preprocessing yang dilakukan adalah dengan mengubah ukuran dan menormalkan nilai piksel pada gambar termasuk pembagian menjadi 80% data latih dan 20% data uji. Data pelatihan dilatih dengan menggunakan model ResNet, InceptionV3, dan Xception yang telah dilatih sebelumnya pada ImageNet. Parameter yang diubah selama pelatihan adalah epoch, momentum, dan learning rate. Model yang dihasilkan kemudian digunakan untuk pengujian. Akurasi, precision, dan recall dipantau untuk menentukan model terbaik untuk melakukan klasifikasi daging dada ayam.

**Hasil:** Akurasi tertinggi yang diperoleh pada penelitian ini adalah 95.67%. Akurasi ini diperoleh dengan metode ResNet dan Inceptionv3. Hasil terbaik ResNet diperoleh dengan learning rate 0.0007, tanpa momentum, dan epoch 200. Hasil terbaik Inceptionv3 diperoleh dengan learning rate 0.0003, momentum 0.9, dan epoch 200.

**Keaslian/ state of the art:** Perbandingan *transfer learning* pada model ResNet, InceptionV3, dan Xception untuk klasifikasi kualitas dada ayam belum pernah dilakukan sebelumnya.

---

## **1. Pendahuluan**

Daging ayam merupakan salah satu jenis daging dengan tingkat konsumsi tertinggi di Indonesia. Dari data Survei Sosial Ekonomi Nasional (SUSENAS), selama rentang waktu 2009 sampai 2018, angka konsumsi per kapita daging ayam di Indonesia meningkat rata-rata sebesar 6,88% per tahun [1]. Daging ayam yang banyak didistribusikan di Indonesia untuk dikonsumsi adalah

daging ayam dengan jenis ayam ras pedaging atau daging ayam broiler. Selain harganya yang terjangkau, daging ayam broiler merupakan salah satu sumber protein hewani yang berkualitas tinggi dan mudah untuk didapatkan. Menurut survei yang dilakukan oleh Badan Pusat Statistik pada tahun 2019, produksi daging ayam ras di Indonesia mencapai angka 3.495.090 ton [2]. Jumlah ini meningkat dibandingkan pada tahun 2018 yang mencapai nilai total produksi sebesar 3.409.558 ton. Jumlah ini bahkan jauh mengungguli nilai produksi daging sapi di Indonesia yang pada tahun 2019 mencapai 515.627 ton [3]. Dari data yang didapat dari tahun 2009 sampai 2019, jumlahnya meningkat secara pesat dari tahun ke tahun, dan diperkirakan akan terus meningkat di waktu yang akan datang.

Dari besarnya angka produksi ayam broiler di Indonesia, ada 4 provinsi yang menyumbangkan jumlah produksi terbanyak, yaitu Jawa Barat (894.386 ton), Jawa Tengah (681.384 ton), Jawa Timur (506.731 ton), dan Banten (221.341 ton). Keempat provinsi tersebut menyumbang sebanyak 65% dari total produksi ayam broiler di Indonesia. Empat provinsi yang menyumbang produksi ayam broiler terbanyak di Indonesia berasal dari pulau Jawa. Hal ini dapat terjadi karena populasi penduduk tertinggi di Indonesia ada di pulau Jawa. Selain keempat provinsi di atas, Sumatera Utara dan Riau yang berada di luar pulau Jawa juga memiliki nilai produksi ayam broiler yang tinggi, sebagaimana ditunjukkan pada **Tabel 1** [2].

**Tabel 1.** Data Produksi Daging Ayam Ras Pedaging menurut Provinsi di Indonesia

No.	Provinsi	Tahun (Dalam Satuan Ton)		
		2017	2018	2019
1.	Jawa Barat	681.781,83	824.405,26	894.386,29
2.	Jawa Tengah	498.751,42	543.754,32	681.384,13
3.	Jawa Timur	472.079,96	480.309,46	506.731,16
4.	Banten	284.380,72	285.064,79	221.341.53
5.	Sumatera Utara	199.760,58	189.271,38	151.595,60
6.	Riau	94.109,64	90.942,85	106.817,03
7.	Provinsi Lainnya	944.993	995.813	932.836

Pola distribusi perdagangan daging ayam ras di Indonesia ada 2 rantai, yaitu dimulai dari Produsen yang menyalurkan kepada Pedagang Eceran, dan kemudian ke Konsumen Akhir [4]. Dikarenakan permintaan yang tinggi, dalam proses pendistribusian ini masih terdapat oknum penjual yang menjual ayam dalam keadaan busuk atau sudah tidak layak konsumsi [5]. Jumlahnya dapat terus meningkat pada momen hari - hari besar keagamaan seperti hari raya Idul Fitri dimana permintaan terhadap daging ayam meningkat. Daging ayam yang membusuk biasanya ditandai dengan munculnya lendir, serta perubahan warna dan bau. Perbedaan citra daging ayam segar dan daging ayam busuk dapat dilihat pada **Gambar 1**. Namun terkadang tanda - tanda tersebut dapat disamarkan dan perbedaannya tidak terlalu terlihat. Maka dari itu, diperlukan sebuah sistem yang dapat membedakan antara daging ayam broiler yang masih segar dan layak konsumsi dengan daging ayam broiler yang sudah busuk dan tidak layak konsumsi.

---

Penelitian untuk membedakan daging ayam segar dan daging ayam busuk telah dilakukan sebelumnya. Penelitian untuk membedakan daging ayam segar dan busuk pada *dataset* citra dada ayam broiler dengan menggunakan metode *convolutional neural network* (CNN) menghasilkan akurasi tertinggi sebesar 92,9% . Akurasi ini dicapai dengan arsitektur yang dibuat sendiri bernama Ayam6Net, mengalahkan hasil akurasi dari arsitektur yang sudah ada seperti AlexNet, VGGNet, dan GoogLeNet [6]. Pada penelitian serupa, digunakan identifikasi dengan fitur warna berupa *channel Red, Green, and Blue* (RGB) dan *Hue, Saturation, Value* (HSV), serta fitur tekstur dengan *Grey Level Co-Occurrence Matrix* (GLCM), Gabor kernel, and *Histogram of Oriented Gradients* (HOG). Hasilnya didapatkan bahwa penggunaan algoritma *Support Vector Machines* (SVM) dapat memberikan akurasi sebesar 98% [7]. Pada penelitian lain, digunakan *Semiconductor Gas Sensor* yang dapat menggantikan peran indra penciuman manusia, dikombinasikan dengan *Image Processing* dengan *Grey Level Co-occurrence Matrix* (GLCM). Hasil deteksi gas dan citra tersebut diproses dengan menggunakan jaringan syaraf tiruan (ANN) dan didapatkan akurasi sebesar 82% [8]. Dari beberapa hasil penelitian yang sudah dilakukan, dapat diketahui bahwa penggunaan algoritma *deep learning* berupa CNN dan *classical machine learning* seperti SVM, keduanya sama-sama dapat memberikan akurasi yang tinggi.



(a) Daging dada ayam segar



(b) Daging dada ayam busuk

**Gambar 1.** Perbandingan daging ayam segar dan daging ayam busuk pada bagian dada ayam

Dalam perkembangannya, *machine learning* banyak menghasilkan metode - metode baru yang dapat meningkatkan nilai akurasi maupun efisiensi. Salah satunya adalah metode *transfer learning*. Ide utama dari *transfer learning* adalah bagaimana kita dapat menggunakan model yang telah dilakukan pelatihan sebelumnya pada kasus yang berbeda, untuk kasus atau permasalahan baru. Dengan menggunakan model yang sudah dilakukan pelatihan sebelumnya, *transfer learning* dapat memberikan performa yang tinggi meskipun menggunakan jumlah sampel yang sedikit [9][10]. *Transfer learning pada deep learning* dapat dilakukan dengan menggunakan model yang sudah dilakukan pelatihan sebelumnya pada permasalahan yang berbeda. Pada kasus *image processing*, terdapat sebuah *dataset* besar yang biasa digunakan untuk proses pelatihan arsitektur *deep learning*, yaitu ImageNet. ImageNet merupakan *dataset* yang terdiri lebih dari 14 juta gambar dari 1000 kelas yang berbeda [11].

---

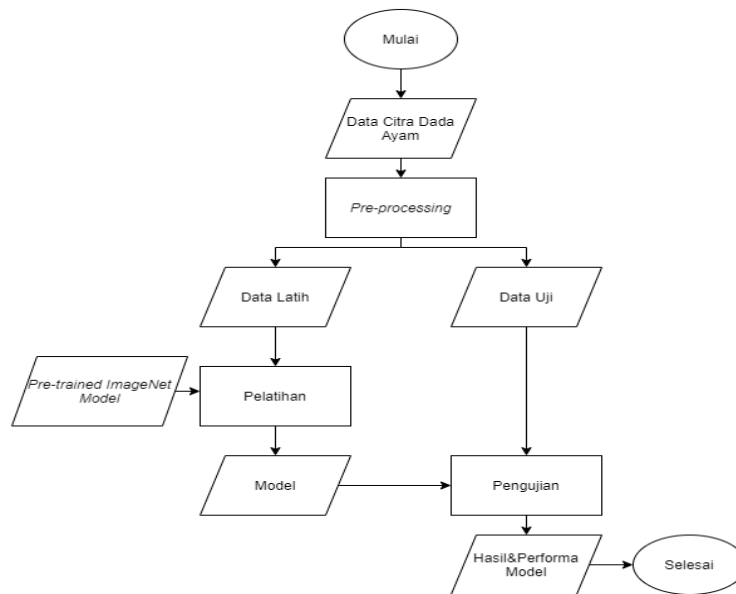
Dalam penelitian ini, digunakan 3 arsitektur *convolutional neural network* (CNN) yang berbeda, yaitu Residual Neural Network (ResNet), Inception, dan Xception yang masing - masing telah dilakukan proses pelatihan terlebih dahulu menggunakan *dataset* ImageNet. Penelitian menggunakan ResNet telah dilakukan sebelumnya pada klasifikasi penyakit malaria dengan citra sel tubuh manusia, dan didapatkan akurasi sebesar 95,4% pada data validasi [12]. Penelitian lain menggunakan ResNet juga dilakukan untuk melakukan klasifikasi *malware* dengan menggunakan data citra *byteplot grayscale images*, dan didapatkan akurasi sebesar 98,62% [13]. Sedangkan penelitian dengan menggunakan arsitektur Inception telah dilakukan sebelumnya pada klasifikasi citra penyakit pada paru-paru. Hasilnya didapatkan akurasi tertinggi menggunakan model Inception dengan klasifikasi Softmax dengan nilai akurasi sebesar 86,40%, dan nilai *sensitivity* sebesar 94,71% [14]. Pada penelitian lain, metode *transfer learning* dilakukan pada arsitektur Inception dan Xception pada kasus klasifikasi COVID-19 dengan menggunakan citra Sinar-X pada dada pasien. Hasilnya didapatkan nilai akurasi untuk arsitektur Inception sebesar 95,78% dan untuk arsitektur Xception sebesar 97,4% [15]. Penelitian lain menggunakan arsitektur Xception telah dilakukan pada klasifikasi sampah dengan menggunakan *dataset* TrashNet, dan didapatkan hasil nilai akurasi sebesar 88% [16].

Hasil eksperimen *transfer learning* pada arsitektur ResNet, Inception, dan Xception menunjukkan nilai akurasi yang tinggi pada kasus yang berbeda - beda. Pada penelitian ini, *transfer learning* pada ketiga arsitektur tersebut digunakan untuk melakukan klasifikasi kesegaran daging ayam broiler. Kesegaran daging ayam broiler diklasifikasikan menjadi dua jenis, yaitu daging ayam busuk dan daging ayam segar. Hasil akurasi *transfer learning* pada algoritma ResNet, Inception, dan Xception yang tinggi pada kasus atau permasalahan yang berbeda-beda, dapat menunjukkan bahwa ketiga arsitektur dapat menunjukkan nilai akurasi yang baik secara umum, sehingga dapat dilihat perbandingannya pada kasus klasifikasi kesegaran daging ayam. Selain itu, penelitian ini ditujukan untuk mengetahui bahwa transfer learning dapat memberikan nilai akurasi tinggi dengan data yang sedikit. Pada penelitian ini juga dilakukan perbandingan pada nilai momentum pada optimasi *Stochastic Gradient Descent* (SGD) dan juga *learning rate* untuk menunjukkan perbedaan nilai akurasinya.

---

## 2. Metode/Perancangan

Penelitian ini dilakukan dengan menggunakan tiga metode yang berbeda yang mempunyai alur yang sama. Penelitian dimulai dengan melakukan *pre-processing* terhadap data citra dada ayam, kemudian data yang sudah diolah akan dibagi menjadi 80% data latih dan 20% data uji. Pada proses pelatihan, ketiga metode sama-sama akan memanggil *pre-trained model* dari *ImageNet* yang ketika diproses dengan data latih akan menghasilkan model yang digunakan untuk klasifikasi. Terakhir model akan dites menggunakan data uji sehingga mendapatkan hasil performa model untuk dibandingkan. Gambaran lengkap alur penelitian dapat dilihat di



**Gambar 2.**

**Gambar 2.** Alur penelitian

### 2.1. Dataset

*Dataset* yang digunakan pada penelitian diambil dari *Fresh and rotten poultry meat datasets* yang berasal dari *website* kaggle. *Dataset* berisi dua kelas dengan masing-masing jumlah kelas segar sejumlah 1000 citra dan kelas busuk sejumlah 300 citra. Contoh citra dari kelas segar dan busuk dapat dilihat pada **Gambar 3**.




(a)




(b)





**Gambar 5.** Modul Inception[18]

Banyaknya informasi yang diproses secara paralel dapat menyebabkan bertambahnya biaya komputasi di metode ini. Pada perkembangannya inception sudah memiliki banyak perubahan yang masing-masing berusaha menutupi kekurangan dari model terdahulu. Model yang digunakan pada penelitian ini adalah Inception V3 yang arsitekturnya dapat dilihat pada **Gambar 6**.

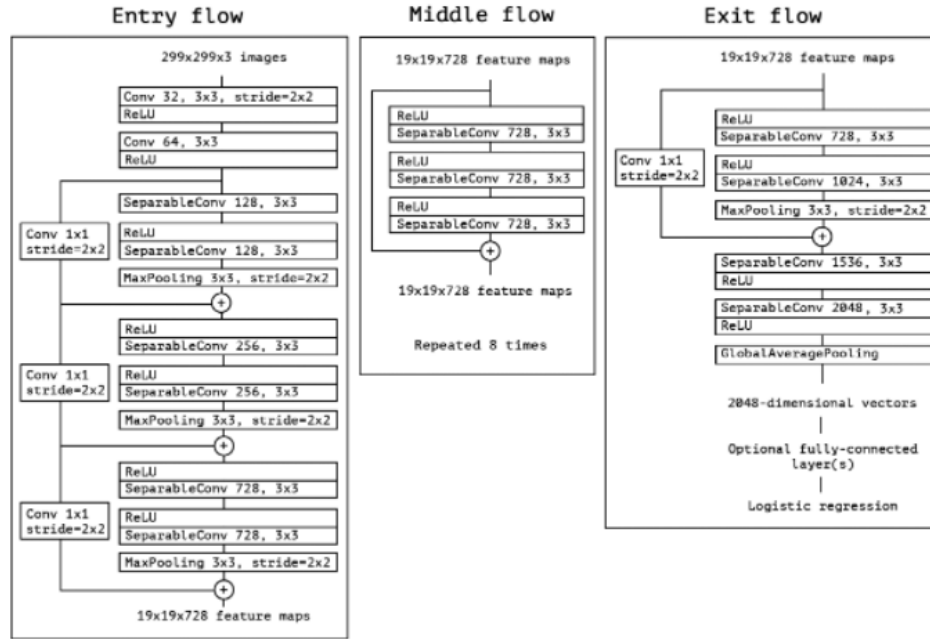


**Gambar 6.** Arsitektur Inception V3

## 2.5. Xception

Xception merupakan metode yang dibuat berdasarkan metode Inception. Xception merupakan kependekan dari *extreme inception* yang dari namanya dapat disimpulkan bahwa metode ini menerapkan prinsip inception secara ekstrim. Salah satu elemen yang penting diperhatikan pada metode Xception adalah *Depthwise separable convolution layer*. Terdapat dua bagian fungsional *depthwise separable layer* yaitu *depthwise convolution* dan *pointwise convolution*. Pada Xception dilakukan *pointwise convolution* terlebih dahulu baru diikuti dengan *depthwise convolution*. Penggantian modul Inception dengan *depthwise separable convolution* terbukti menunjukkan performa yang lebih baik dari Inception V3[19]. Arsitektur Xception dapat dilihat pada **Gambar 7**.





**Gambar 7.** Arsitektur Xception[19]

## 2.6. Evaluasi Model

Evaluasi model dilakukan dengan melihat *confusion matrix* pada tiap metode yang digunakan. *Accuracy*, *precision*, dan *recall* akan dihitung dari nilai *true positive*, *true negative*, *false positive*, *false negative*. *True positive (tp)* adalah data dada ayam kelas segar yang diprediksi ke kelas segar. *True Negative (tn)* adalah data dada ayam kelas busuk yang diprediksi ke kelas busuk. *False positive (fp)* adalah data dada ayam kelas busuk yang diprediksi ke kelas segar. *False negative (fn)* adalah data dada ayam kelas segar yang diprediksi ke kelas busuk.

Penghitungan *accuracy*, *precision*, dan *recall* dapat digambarkan menjadi persamaan (1)(2)(3)

$$accuracy = (tp + tn) / (tp + tn + fp + fn) \quad (1)$$

$$precision = (tp) / (tp + fp) \quad (2)$$

$$recall = tp / (tp + fn) \quad (3)$$

## 2.7. Skenario Penelitian

Skenario yang dilakukan pada penelitian ini adalah sebagai berikut:

### 2.7.1.Skenario 1

Pada skenario 1, pelatihan dilakukan dengan menggunakan nilai momentum (0), tiga macam *learning rate* yaitu (0,0001), (0,0003), (0,0007), dan *epochs* sebanyak 100 dan 200 dengan *batch* 10.

---

### 2.7.2.Skenario 2

Pada skenario 2, pelatihan dilakukan dengan menggunakan nilai momentum (0,9), tiga macam *learning rate* yaitu (0,0001), (0,0003), (0,0007), dan *epochs* sebanyak 100 dan 200 dengan *batch* 10.

## 3. Hasil dan Pembahasan

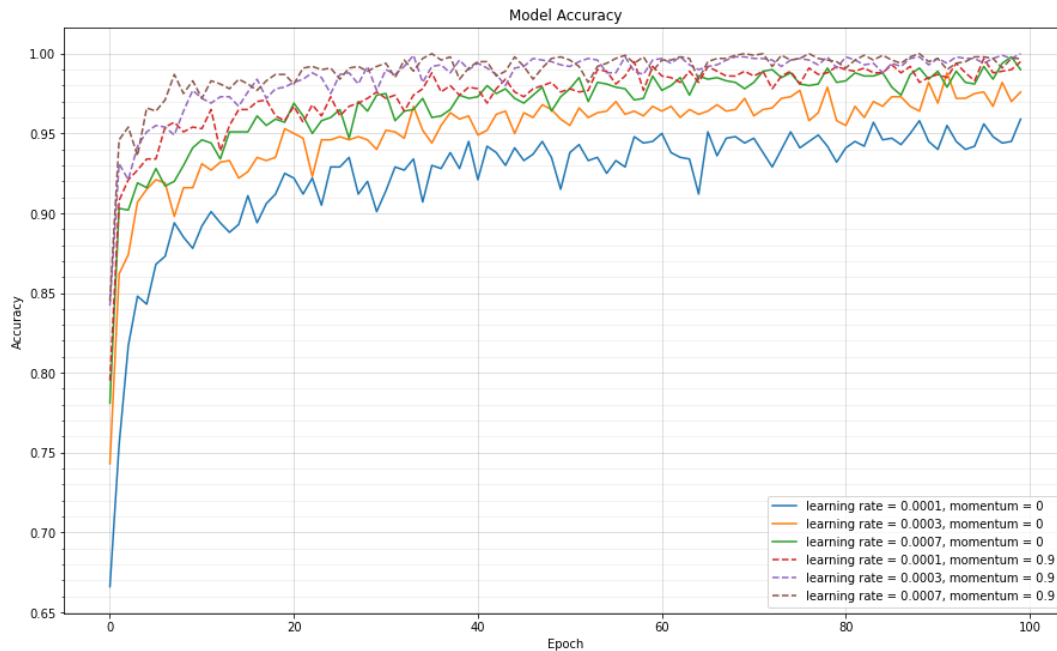
Proses pelatihan klasifikasi kualitas kesegaran daging ayam dilakukan dengan 3 model yaitu ResNet yang ditunjukkan pada **Gambar 8** dan **Gambar 9**, Inceptionv3 yang ditunjukkan pada **Gambar 10** dan **Gambar 11**, dan Xception yang ditunjukkan pada **Gambar 12** dan **Gambar 13**. Pelatihan yang tidak menggunakan momentum ditunjukkan oleh garis berkelanjutan dengan warna biru ( $lr = 0.0001$ ), warna kuning ( $lr = 0.0003$ ), dan warna hijau ( $lr = 0.0007$ ), sedangkan pelatihan menggunakan momentum 0.9 ditunjukkan oleh garis putus-putus warna merah ( $lr = 0.0001$ ), warna ungu ( $lr = 0.0003$ ), dan warna coklat ( $lr = 0.0007$ ). Dari hasil pelatihan yang dilakukan pada ketiga model, dapat dilihat bahwa *learning rate* mempengaruhi kecepatan pelatihan. Pada **Gambar 5** sampai **Gambar 13**, *learning rate* yang lebih tinggi mengalami peningkatan akurasi yang lebih besar untuk jumlah *epoch* yang sama. Grafik hasil penelitian menunjukkan bahwa meningkatkan *learning rate* dapat mempercepat proses pelatihan untuk ketiga model. Hal ini disebabkan karena *learning rate* mempengaruhi perubahan bobot pada setiap iterasi pelatihan. Semakin tinggi *learning rate*, maka semakin besar perubahan bobot pada proses pelatihan.

Proses pelatihan klasifikasi kesegaran daging ayam dapat dipercepat dan ditingkatkan akurasinya dengan menggunakan momentum. Pada **Gambar 8** dan **Gambar 9**, momentum pada model ResNet mempercepat proses pelatihan, namun tidak menghasilkan akurasi akhir yang lebih baik dari pelatihan yang tidak menggunakan momentum. Pada **Gambar 10** dan **Gambar 11**, momentum pada model Inceptionv3 mempercepat proses pelatihan menghasilkan akurasi akhir yang lebih baik dari pelatihan yang tidak menggunakan momentum. Pada **Gambar 11** dan **Gambar 12**, penggunaan momentum menyebabkan model Xception kesulitan untuk mencapai konvergen. Hal ini ditunjukkan dengan garis pelatihan yang naik turun secara ekstrim. Kesulitan konvergen pada model Xception disebabkan oleh perubahan bobot yang terlalu ekstrem pada setiap *epoch*.

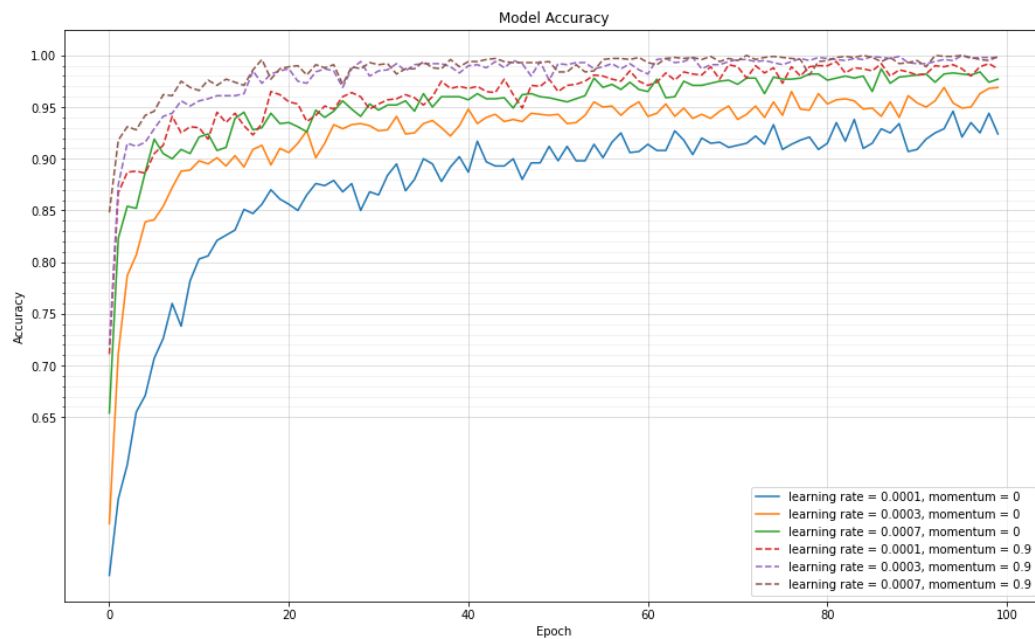
Hasil pelatihan dengan jumlah *epoch* 200 pada **Gambar 9**, **Gambar 11**, dan **Gambar 13** menunjukkan bahwa untuk *learning rate* kecil, semakin banyak *epoch* maka akan semakin konvergen. Hal ini disebabkan karena perubahan bobot yang minimum untuk *learning rate* rendah. Pada pelatihan model ResNet dan Xception yang menggunakan momentum, akurasi pada pelatihan dengan *epoch* berjumlah 200 lebih buruk dibandingkan dengan *epoch* berjumlah 100. Pada **Gambar 13**, grafik akurasi untuk pelatihan model Xception dengan menggunakan momentum menghasilkan garis yang fluktuatif. Akurasi yang fluktuatif menunjukkan bahwa perubahan bobot pada setiap iterasi terlalu besar. Hasil akurasi akhir menjadi kurang valid

---


karena hasil pelatihan dapat berbeda jauh untuk pelatihan berbeda dengan konfigurasi yang sama. Pada **Gambar 9**, model ResNet memiliki masalah yang sama dengan model Xception namun tidak separah model Xception.



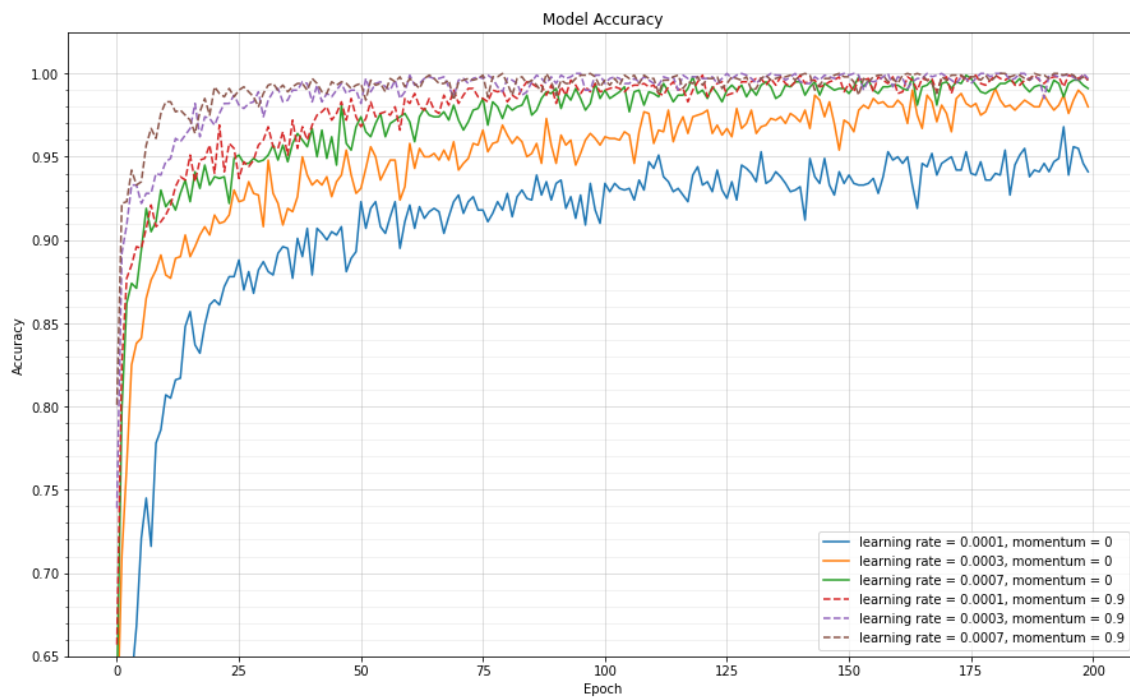
**Gambar 8.** Pelatihan model ResNet untuk *epoch* 100




**Gambar 9.** Pelatihan model ResNet untuk *epoch* 200



**Gambar 10.** Pelatihan model Inceptionv3 untuk *epoch* 100



**Gambar 11.** Pelatihan model Inceptionv3 untuk *epoch* 200



**Gambar 12.** Pelatihan model Xception untuk *epoch* 100



**Gambar 13.** Pelatihan model Xception untuk *epoch* 200

Akurasi pengujian untuk skenario 1 dan 2 pada model ResNet, Inceptionv3, dan Xception dapat dilihat pada **Tabel 2**. Pada tabel tersebut, akurasi pengujian tertinggi pada skenario 1 didapatkan oleh ResNet dengan akurasi 95.67% untuk *learning rate* 0.0007 dan *epoch* 200. Pada skenario 2, akurasi pengujian tertinggi adalah pelatihan model Xception dengan akurasi 96.33% untuk *learning rate* 0.0007 dan *epoch* 100. Namun, jika dilihat pada **Gambar 12**, ada kemungkinan bahwa hasil ini hanya kebetulan karena grafik akurasi bersifat fluktuatif dan tidak konvergen. Akurasi pengujian tertinggi kedua pada skenario 2 adalah pelatihan model Inceptionv3 dengan akurasi 95.67% untuk *learning rate* 0.0003 dan *epoch* 200. Pada **Gambar 11**, peningkatan akurasi untuk model Inceptionv3 lebih gradual dan konvergen dibandingkan dengan model Xception. Hal ini menunjukkan bahwa akurasi prediksi model Inceptionv3 untuk *dataset* kualitas kesegaran ayam yang baru, kemungkinan lebih baik dibandingkan dengan prediksi model Xception.

**Tabel 2.** Akurasi pengujian dari hasil penelitian dan pengujian dengan ResNet, Inceptionv3, dan Xception

Hyperparameter	ResNet		Inceptionv3		Xception	
	<i>Epoch</i> 100	<i>Epoch</i> 200	<i>Epoch</i> 100	<i>Epoch</i> 200	<i>Epoch</i> 100	<i>Epoch</i> 200
lr=10 <sup>-4</sup> m=0	92.33%	93.0%	90.33%	93.33%	89.99%	91.66%
lr=3.10 <sup>-4</sup> m=0	<b>95.33%</b>	95.0%	<b>94.0%</b>	91.33%	91.33%	93.00%
lr=7.10 <sup>-4</sup> m=0	94.67%	<b>95.67%</b>	91.0%	92.33%	92.66%	<b>94.33%</b>
lr=10 <sup>-4</sup> m=0.9	93.67%	91.0%	92.33%	93.67%	93.33%	92.66%
lr=3.10 <sup>-4</sup> m=0.9	92.67%	91.67%	93.33%	<b>95.67%</b>	92.66%	92.66%
lr=7.10 <sup>-4</sup> m=0.9	92.0%	90.67%	91.33%	93.33%	<b>96.33%</b>	92.00%

**Tabel 3.** *Confussion matrix* hasil pelatihan Inceptionv3 terbaik

Kelas sebenarnya \ Prediksi	Busuk	Segar
Busuk	144	6
Segar	7	143

Busuk memiliki precision 0.95 dan recall 0.96, Segar memiliki precision 0.96 dan recall 0.95

---

#### 4. Kesimpulan dan Saran

Penelitian ini bertujuan untuk mencari model *deep learning* terbaik untuk klasifikasi kualitas daging dada ayam broiler. Tiga model *deep learning* yaitu ResNet, Inceptionv3, dan Xception, dilatih untuk membedakan daging dada ayam busuk dan segar berdasarkan gambar. Jumlah data yang digunakan pada penelitian ini adalah 1000 kelas segar dan 300 kelas busuk. Dalam pelaksanaan penelitian, parameter yang diubah adalah *learning rate*, momentum, dan epoch. Hasil penelitian menunjukkan bahwa model Xception mencapai akurasi tertinggi sebesar 96.33%, namun karena grafik sangat fluktuatif, akurasi tersebut dianggap hanya kebetulan. Akurasi tertinggi kedua adalah pelatihan dengan model ResNet dan Inceptionv3 dengan akurasi sebesar 95.67%. Pada model ResNet, akurasi tersebut dicapai dengan *learning rate* 0.0007, momentum 0, dan *epoch* 200. Pada model Inceptionv3, akurasi tersebut dicapai dengan *learning rate* 0.0003, momentum 0.9, dan *epoch* 200.

#### Daftar Pustaka

- [1] Kementerian Pertanian Republik Indonesia, "Outlook Daging Ayam Ras Pedaging 2019," 2020. [Online]. Available: [epublikasi.pertanian.go.id](http://epublikasi.pertanian.go.id). [Accessed: 13-Jun-2021].
- [2] Badan Pusat Statistik, "Produksi Daging Ayam Ras Pedaging di Indonesia menurut Provinsi, 2009-2019," 2019. [Online]. Available: [bps.go.id](http://bps.go.id). [Accessed: 13-Jun-2021].
- [3] Badan Pusat Statistik, "Produksi Daging Sapi di Indonesia menurut Provinsi, 2018-2019," 2020. [Online]. Available: [bps.go.id](http://bps.go.id). [Accessed: 13-Jun-2021].
- [4] Badan Pusat Statistik, "Distribusi Perdagangan Komoditas Daging Ayam Ras Indonesia 2019," 2019. Jakarta.
- [5] Harian Jogja, "Daging Ayam Busuk dan Daging Sapi Bercacing Ditemukan di Pasar Kota Magelang," 2021. [Online]. Available: <https://news.harianjogja.com/read/2021/05/10/500/1071398/daging-ayam-busuk-dan-daging-sapi-bercacing-ditemukan-di-pasar-kota-magelang>. [Accessed: 13-Jun-2021].
- [6] Calvin, G. B. Putra and E. Prakasa, "Classification of Chicken Meat Freshness using Convolutional Neural Network Algorithms," 2020 *International Conference on Innovation and Intelligence for Informatics, Computing and Technologies (3ICT)*, 2020, pp. 1-6, doi: 10.1109/3ICT51146.2020.9312018.
- [7] Asmara, R. A., Hasanah, Q., Rahutomo, F., Rohadi, E., Siradjuddin, I., Ronilaya, F., & Handayani, A. N, "Chicken Meat Freshness Identification using Colors and Textures Feature," in *2018 Joint 7th International Conference on Informatics, Electronics & Vision (ICIEV) and 2018 2nd International Conference on Imaging, Vision & Pattern Recognition (icIVPR)*, pp. 93-98, June 2018, IEEE.
- [8] Kartika, V. S., Rivai, M., & Purwanto, D., "Spoiled Meat Classification Using Semiconductor Gas Sensors, Image Processing and Neural Network," in *2018 International Conference on Information and Communications Technology (ICOIACT)*, pp. 418-423, March 2018, IEEE.

- 
- [9] K. Wang, X. Gao, Y. Zhao, X. Li, D. Dou, and C.-Z. Xu, "Pay Attention to Features, Transfer Learn Faster CNNs," *8th Int. Conf. Learn. Represent. ICLR 2020 - Conf. Track Proc.*, pp. 1–14, 2020.
  - [10] Zhao, W., "Research on The Deep Learning of The Small Sample Data Based on Transfer Learning," in *AIP Conference Proceedings (Vol. 1864, No. 1, p. 020018)*, AIP Publishing LLC, August 2017.
  - [11] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and F.-F. Li, "ImageNet: A Large-Scale Hierarchical Image Database," in *2009 IEEE conference on computer vision and pattern recognition*, 2009, pp. 248–255.
  - [12] Reddy, A. S. B., & Juliet, D. S., "Transfer Learning with ResNet-50 for Malaria Cell-Image Classification," in *2019 International Conference on Communication and Signal Processing (ICCSP)*, pp. 0945-0949, April 2019, IEEE.
  - [13] Rezende, E., Ruppert, G., Carvalho, T., Ramos, F., & De Geus, P., "Malicious Software Classification using Transfer Learning of ResNet-50 Deep Neural Network," in *2017 16th IEEE International Conference on Machine Learning and Applications (ICMLA)*, pp. 1011-1014, December 2017, IEEE.
  - [14] Wang, C., Chen, D., Hao, L., Liu, X., Zeng, Y., Chen, J., & Zhang, G., "Pulmonary Image Classification Based on Inception-v3 Transfer Learning Model," *IEEE Access*, 7, 146533-146541, 2019.
  - [15] Das, N. N., Kumar, N., Kaur, M., Kumar, V., & Singh, D., "Automated Deep Transfer Learning-Based Approach for Detection of COVID-19 Infection in Chest X-rays," *Irbm*, 2020.
  - [16] Rismiyati, S. N. Endah, Khadijah and I. N. Shiddiq, "Xception Architecture Transfer Learning for Garbage Classification," *2020 4th International Conference on Informatics and Computational Sciences (ICICoS)*, 2020, pp. 1-4, doi: 10.1109/ICICoS51170.2020.9299017.
  - [17] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, vol. 2016-December, pp. 770–778, 2016, doi: 10.1109/CVPR.2016.90.
  - [18] C. Szegedy *et al.*, "Going deeper with convolutions," *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, vol. 07-12-June, pp. 1–9, 2015, doi: 10.1109/CVPR.2015.7298594.
  - [19] F. Chollet, "Xception: Deep learning with depthwise separable convolutions," *Proc. - 30th IEEE Conf. Comput. Vis. Pattern Recognition, CVPR 2017*, vol. 2017-January, pp. 1800–1807, 2017, doi: 10.1109/CVPR.2017.195.